JEV-as-a-Judge
: Accept When Confident, Escalate When Unsure

Yubo Li, Yidi Miao, Ramayya Krishnan, Rema Padman | Carnegie Mellon University (CMU) | 2026 | arXiv:2609.26550

Jev

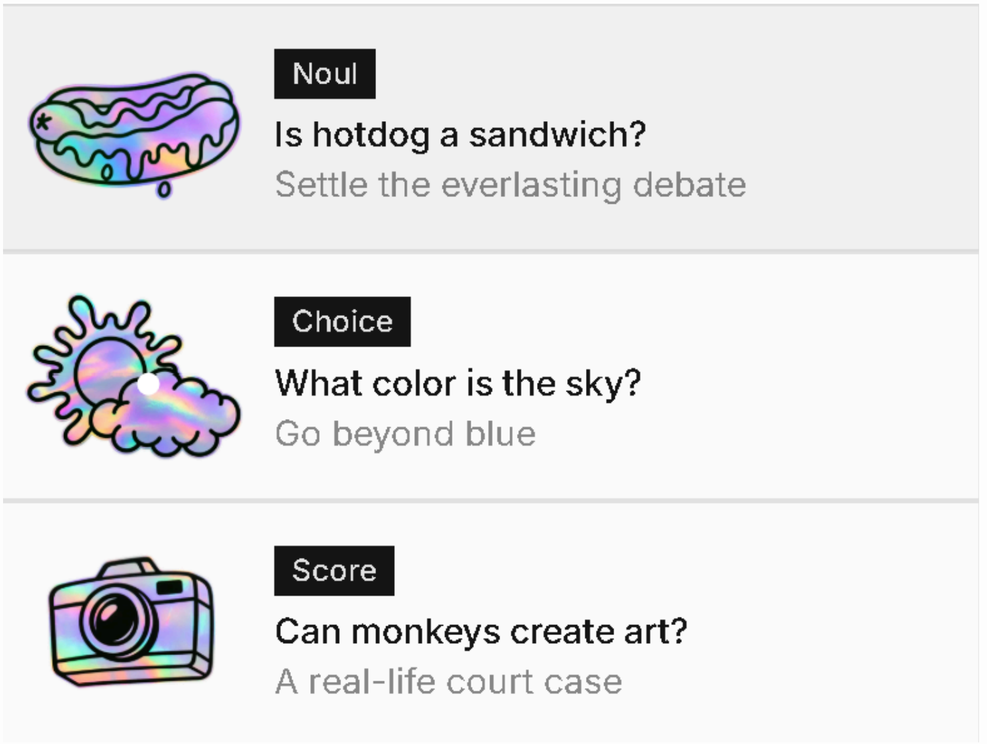


Ref: turtle_step_ @th ads

Jev

OpenAI 출신 창업자가 이끄는 TypeSafe AI 에서 2026년 9월 15일에 발표한 모델

1. **Noul**
   - 예/아니오 질문을 평가하고 답변이 예일 확률 반환
2. **Choice**
   - 정의된 집합에서 (순서 x) 한개의 옵션을 선택하는 질문 유형
   - 답변: 선택된 옵션, 각 옵션의 확률, confidence를 포함
3. **Score**
   - 순서가 지정된 서술형 수준에 따라 점수를 매기는 질문 유형
   - 답변: 점수, 각 수준에 대한 확률, confidence를 포함



※ 확률은 후보별 판단을 읽는 값이고, confidence는 그 판단을 얼마나 확실하게 다룰지 검토하는 별도의 신호

e.g. 어느 부서가 더 적절한지와 (판단에 대한 확률), 자동으로 보내도 될 만큼 판단이 분명한지 (confidence)

기존의 LLM vs JeV

제번스의 역설 (Jevons Paradox) : 자원을 쓰는 효율이 좋아질수록, 오히려 그 자원의 전체 소비량이 폭증한다는 경제학 이론

→ AI를 통해 의사결정 비용이 낮아지면, 시스템 내에서 처리해야 하는 결정과 판단의 수요가 폭발적으로 늘어난다

LLM

- **열린 답변 공간**에서 새로운 문장 **생성**
- 출력 : 토큰 단위로 생성한 문자열
- 이후 해당 문자열을 파싱하고 유효한지 검증
  + 검증 실패시 재시도
- **순차 샘플링 (토큰 단위)**
- task의 긴급성, 위험도 등 고빈도 소규모 판단을 내릴 때 **불필요한 토큰 비용, 재시도에 따른 연쇄 지연** 등 발생
- RLHF (인간 피드백 기반 강화학습)

Jev

- **제한된 공간**에서 가장 최적의 경로를 찾는 **결정형 AI**
- 출력 : 사전 정의된 스키마(타입)에 맞는 값
  + 확률값 (분류, 예/아니오 판정 등)
- **병렬 샘플링** : 요청의 모든 질문을 동시에 평가해서, 질문의 개수에 따라 응답시간이 거의 변하지 않는다
- 지연 시간: 70ms ~ 500ms
- 입력 비용: 100만 토큰당 $0.042 / 출력 비용: 0원
- RLCD (보정된 결정을 위한 강화학습)

Motivation

모든 판정에 비싼 LLM judge가 필요한가? : **Accept When Confident, Escalate When Unsure**

- **Accept When Confident**

  : JEV가 판단 결과에 높은 확신을 보이면, 그 결과를 그대로 채택 (저비용의 1차 필터)

- **Escalate When Unsure**

  : JEV의 확신이 낮으면, 더 강력한 추론 능력의 LLM 평가자에게 판단을 넘겨 다시 평가



기존 LLM의 문제

1. **비용과 속도**
   - 판단할 때마다 텍스트 생성과 추론 연산 필요, 쉬운 문제에서도 불필요한 연산 유발
2. **신뢰성**
   - Overconfidence (과신) : 자신의 판단에 대한 확신도를 실제 정확도보다 높게 추정

Method : Cascade

1. Judging request : 평가 요청 입력

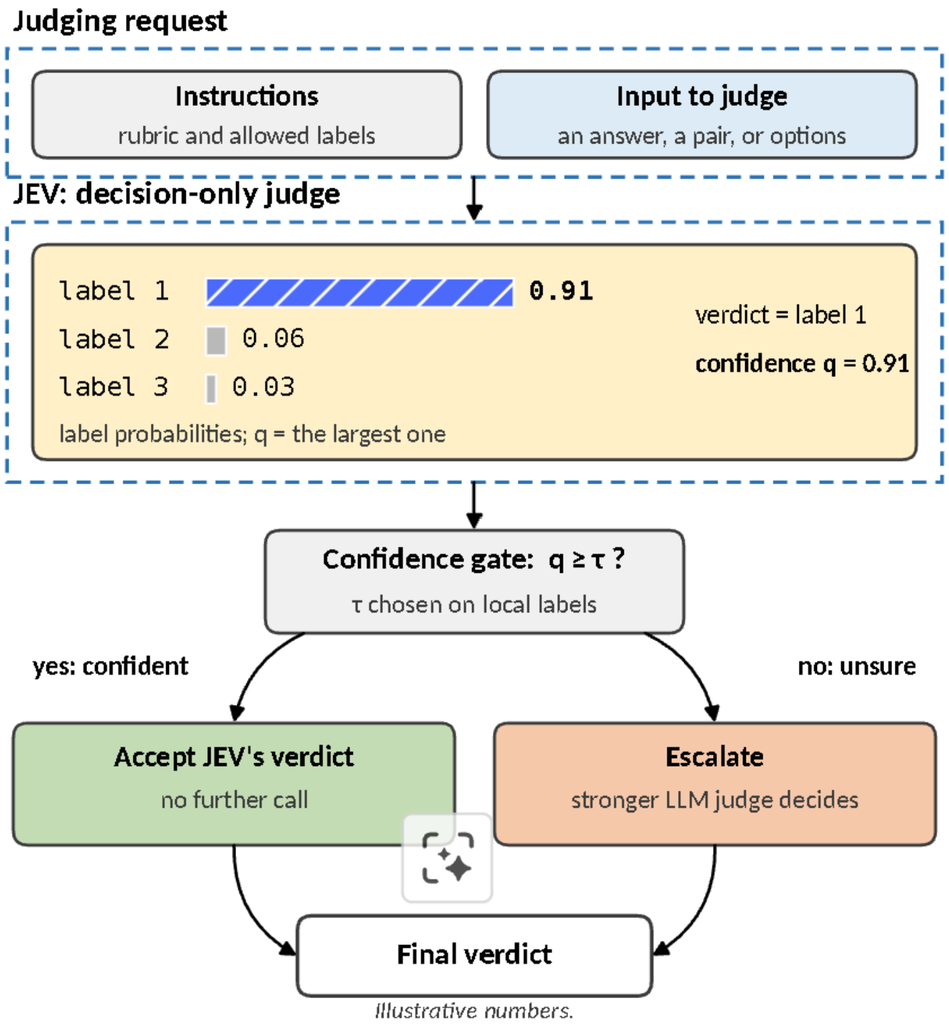
- Input to judge : 실제로 평가할 답변 하나, 답변 쌍, 또는 선택지들
  - e.g. 질문이 “파이썬에서 리스트를 정렬하는 방법은?” 일때
  - 답변 A: my_list.sort()를 사용하면 리스트 자체 정렬 가능
  - 답변 B: my_list.sort()는 정렬된 새 리스트를 반환
- Instructions : 평가 기준(rubric)과 허용된 레이블(label) 지정
  - A의 답변이 더 좋음 / B: B의 답변이 더 좋음 / Tie: 두 답변이 비슷

2. JEV: decision-only judge

- verdict : 확률이 가장 높은 label
- confidence: verdict 레이블에 대한 확률

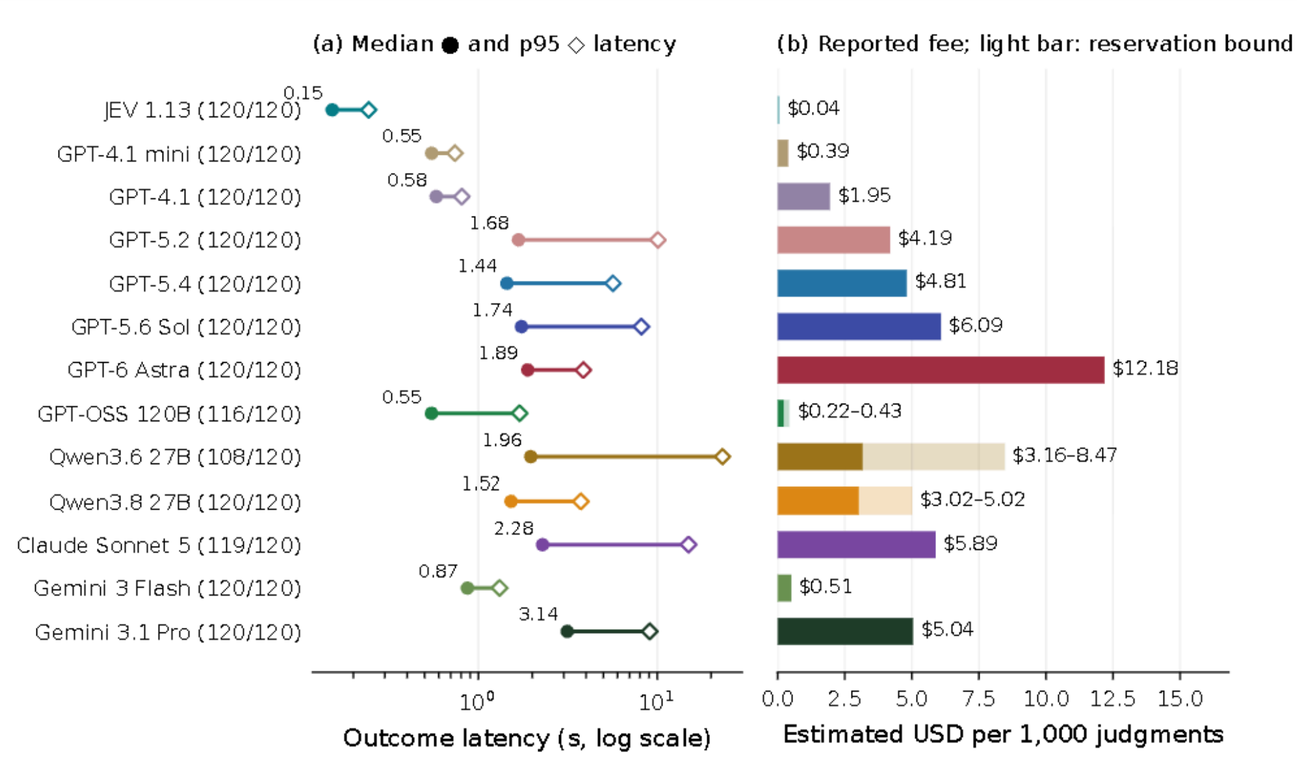
3. Confidence gate : 확신도 기준으로 분기

4. Final verdict : JEV 또는 상위 LLM의 최종 판단



Experiments：Latency & Cost

전체 16개 평가 모델 (생성형 LLM 14개, Reward Model 2개) 중, 비용·지연 시간은 측정 가능한 호스팅 모델 중심으로 비교



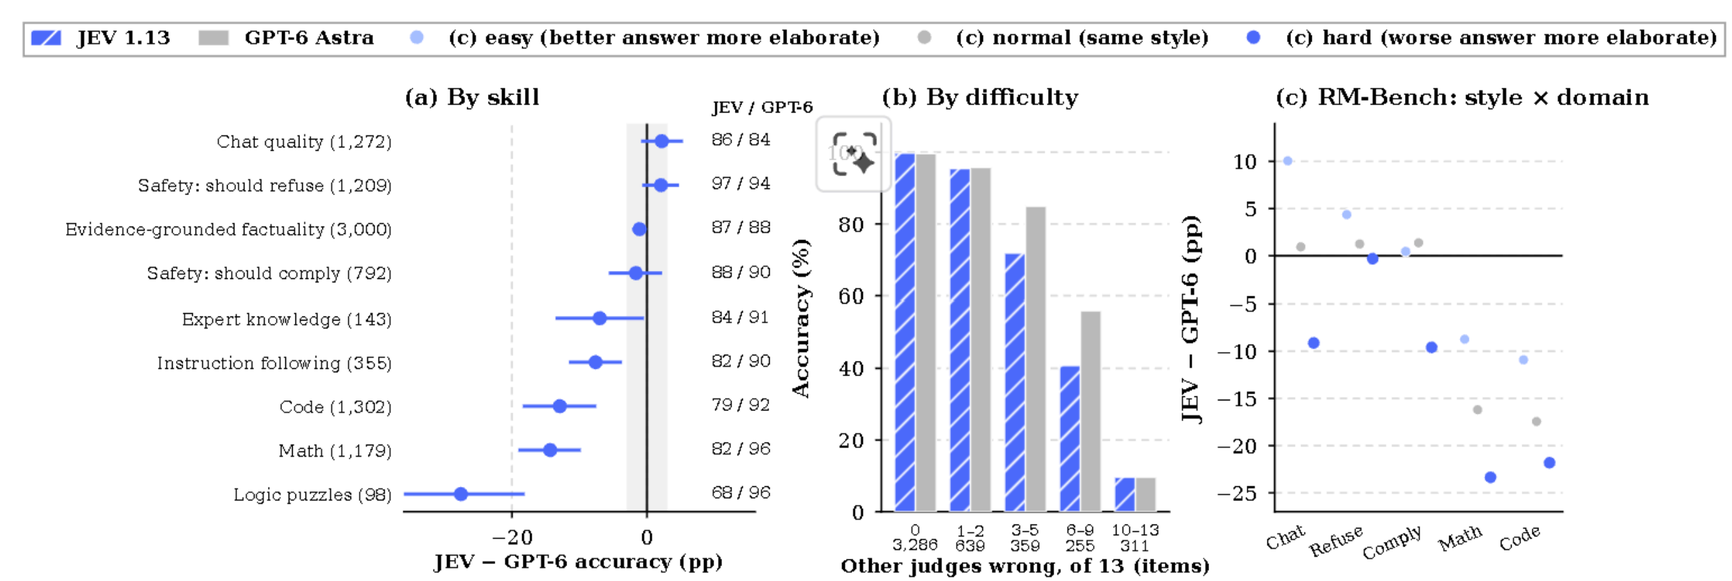
1.Latency (지연시간)

- (●) : 중앙값 / (◇) : 95 백분위수
- 가장 고성능 모델로 언급되는 GPT-6 Astra는 1.89초인 반면, JEV 1.13은 0.15초의 중앙값으로, 테스트된 모델 중 가장 빠른 응답 속도

2. Cost (비용) -1,000건의 판단 기준

- JEV 1.13은 1,000건당 $0.04로 매우 저렴. 가장 비싼 GPT-6 Astra($12.18)와 비교했을 때 약 300배 가까이 경제적임

Experiments：Accuracy Across Task Domains (JEV / GPT-6)



(a) Safety: should refuse (97 / 94), Chat quality (86 / 84):

- 단순한 분류나 판단 영역, 일반적인 대화 품질 평가에서는 JEV가 GPT-6보다 다소 우세한 성능을 보임.

(a) 기타 영역 (예: Math, Code, Logic puzzles 등)

- 복잡한 추론이 필요한 영역에서는 JEV의 정확도가 GPT-6보다 현저히 낮게 나타남

(b) 작업 종류와 무관한, 난이도별 비교 : 대부분의 모델이 맞히는 쉬운 문제에서는 성능 차이가 거의 없지만, 고난이도일 수록 격차가 벌어짐

(c) 스타일/문맥별 비교 : Hard 조건에서 JEV의 성능이 떨어지는 것을 통해, 내용의 정합성보다는 **화려한 문체에 잘 속는다**

Results: Confidence-based Cascade

정확도

93.4%

(GPT-6 단독 92.5% 대비 +0.9p)

상위 LLM 호출 : 31.5%

비용

41.4%

(GPT-6 단독 사용 비용 대비)

JEV 오류 중 Cascade가 보완한 비율 : 85%

Held-out pairs	JEV alone	Cascade	GPT-6	Δ (pp) [95% CI]	Escalated (%)	JEV errors caught (%)	Fee ratio reported / upper
RewardBench (1,340)	92.8	93.7	92.4	+1.27 [0.45, 2.03]	24.8	82	0.267 / 0.308
JudgeBench (270)	81.3	92.2	93.0	−0.74 [−2.22, 0.74]	64.8	90	0.668 / 0.668
All held-out pairs (1,610)	90.9	93.4	92.5	+0.93 [0.24, 1.66]	31.5	85	0.414 / 0.440

Limitations

평가 범위 및 일반화의 한계

- 주어진 후보 답변을 평가하는 작업 위주로 실험했으며, 자유 형식 텍스트나 전문 분야에 대한 검증은 부족
- 새로운 작업에 대한 실시간 검증도 두 종류의 작업, 570개 평가 쌍에 한정됨.

복잡한 추론 및 확신도 판단의 한계

- 수학·코드·논리 문제에서 GPT-6보다 정확도가 낮으며, 답변의 문체에 영향을 받아 오답을 선택할 수 있음
- 확신도가 높더라도 오답일 수 있어, 확신도만으로 오류를 완전히 판별하기 어려움.

모델 내부 구조의 불투명성

- TypeSafe의 독점 API 모델을 사용해 학습 데이터, 모델 규모, 학습 방식 등을 확인할 수 없음.

Cascade 설계의 한계

- 독립적인 판정 모델에 순차적으로 판단을 넘기는 단순한 2단계 구조만 평가함.
- 두 모델이 동일한 오류를 내는 경우에는 추가적인 정확도 개선이 어려움.

Conclusion & Impact

Confidence-based Cascade 검증

- JEV의 판단 확신도에 따라 결과를 수용하거나 GPT-6에 넘기는 전략을 평가

작업별 성능 및 신뢰도 분석

- 일반적인 평가와 복잡한 추론 작업에서 JEV의 성능 차이를 분석
- 확신도가 오답을 식별하고 상위 모델로 판단을 넘기는 기준으로 얼마나 유용한지 검증

LLM과의 상호 보완적 활용 가능성

- 생성형 모델을 완전히 대체하기 보다는, **저비용 판단 모델과 고성능 LLM을 결합한 평가 시스템의 가능성을 제시**
- 저비용 판단 모델: 일반적인 결과 평가 및 확신도가 높은 판단 처리
- 고성능 LLM: 확신도가 낮거나 복잡한 추론이 필요한 판단 처리