Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

LEWIS, Patrick, et al. | Facebook AI Research (FAIR), University College London (UCL), New York University (NYU) | 2020 (NeurIPS 2020)

Motivation

LM의 지식은 파라미터에 갇혀 있다 : 지식갱신, 출처 제시, 정확한 사실 접근이 어렵다.

→ 특히 지식 집약형 작업 (Open domain QA, 장문 응답 생성, fact verification) 에서 이 한계가 치명적

Parametric - only LM (BART, T5 등)

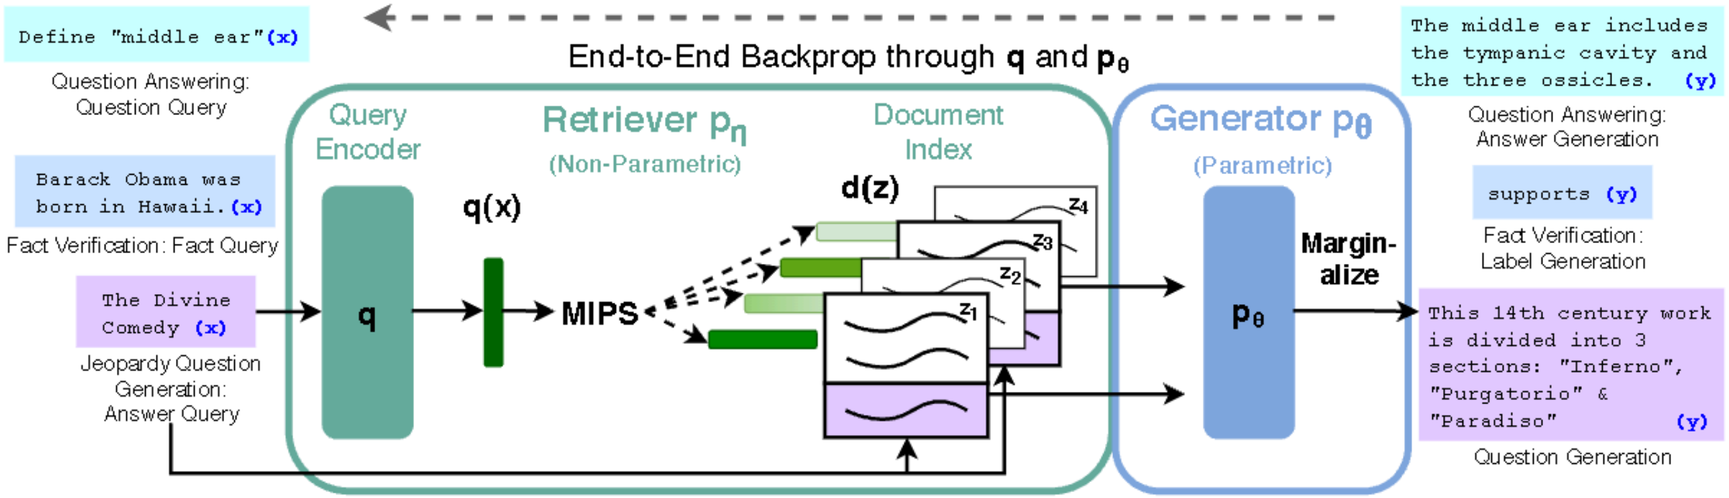
- 사전 학습 : 외부 메모리 접근 없이 task 수행 가능
- 지식이 가중치에 암묵적으로 저장
- 지식 갱신 = 재학습 → 비용 ↑
- 출처 제시 불가, haullucination 발생

Retrieve-and-Extract (REALM, ORQA 등)

- 검색+ 추출형(extractive) QA 중심
- 문서에서 span을 뽑는 방식→ 자유생성불가
- 주로open-domain QA에한정

파라메트릭 메모리(seq2seq 트랜스포머 BAR) + 비파라메트릭 메모리(검색인덱스) 결합 → 범용 "생성" 과제에적용

Pipeline



- **Retriever (비파라메트릭 메모리)**
  - 입력 질의 (x)를 받아 Query Encoder 를 통해 벡터 q(x)로 변환, 문서는 Context encoder로 임베딩
  - 이후 Document Index에서 질의와의 내적 유사도(dot product)를 계산해 top-k 문서를 선택
  - 성능은 retriever의 품질에 민감 → retriever 성능이 높을수록 hallucination이 줄어듬
- **Generator (파라메트릭 메모리)** : 검색된 문서(z)를 입력, 입력 질의(x)를 조건으로 최종 출력(y)를 생성하는 BART 모델
- **End-to-End Backprop** : Query Encoder 와 Generator가 함께 학습 : 검색된 문서들을 잠재 변수로 취급

Method : RAG-Sequence vs RAG-Token

검색된 문서를"언제" 반영하느냐에 따른 두가지 버전

RAG-Sequence : 하나의 문서 전체를 조건으로 생성

$$p_{\text{RAG-Sequence}}(y|x) \approx \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) p_\theta(y|x,z) = \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) \prod_i^N p_\theta(y_i|x,z,y_{1:i-1})$$

- 추론 시 생성 방식: 합산이 문장 전체 단위이므로, 문서별 beam search 후 합산 (Thorough / Fast)
- 하나의 고정된 문서를 참조하므로 일관성 ↑
- 단일 근거 문서로 답이 정해지는 QA에 적합

RAG-Token : 각 토큰 생성마다 다른 문서를 참조

$$p_{\text{RAG-Token}}(y|x) \approx \prod_i^N \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) p_\theta(y_i|x,z,y_{1:i-1})$$

- 추론 시 생성 방식: 토큰 단위로 문서를 주변화한 분포가 나오므로 표준 beam search 사용 가능
- 여러 문서 정보를 조합해야 하는 생성에 적합

Results : Open-domain QA

closed-book과 extractive 방식을 모두 넘어 NQ, WQ, CT에서 SOTA 달성 (평가 지표 : Exact Match)

1. **Closed-book 모델 (T5-11B+SSM) 대비 향상**
   - NQ 36.6 → **44.5 (+7.9p)**
   - 훨씬 작은 모델로도 외부 지식을 검색하면 더 높은 성능을 보임
   - 파라미터를 키우지 않아도 비파라메트릭 메모리로 지식을 보강할 수 있음

2. **Open-book 모델 (DPR) 대비 향상**
   - NQ 41.5 → **44.5 (+3.0p)**, CT 50.6 → **52.2**
   - 문서에서 span을 뽑는 방식이 아니라 직접 생성하는데도 더 높음
   - 정답이 문서에 그대로 없어도 여러 정보를 조합해 답변 가능

	Model	NQ	TQA	WQ	CT
Closed Book	T5-11B [52]	34.5	- /50.1	37.4	-
	T5-11B+SSM[52]	36.6	- /60.5	44.7	-
Open Book	REALM [20]	40.4	- / -	40.7	46.8
	DPR [26]	41.5	**57.9**/ -	41.1	50.6
	RAG-Token	44.1	55.2/66.1	**45.5**	50.0
	RAG-Seq.	**44.5**	56.8/**68.0**	45.2	**52.2**

- NQ : 실제 Google 검색 질문
- TQA : 트리비아 퀴즈 질문 (세부 사실 지식 필요)
- WQ : Google Suggest 기반의 짧은 질문
- CT : TREC QA 대회의 사실형 질문

Results : Generation, Classification & Index Swap

QA 이외 과제에서도 효과, 인덱스 교체만으로 지식 갱신 가능

Jeopardy 질문 생성

- Q-BLEU-1: RAG-Token 22.2 vs BART 19.7
- 사람 평가: factuality RAG 42.7% vs BART 7.1%
- specificity도 RAG 우세 (37.4% vs 16.8%)

FEVER 사실 검증

- 3-way 라벨 정확도 72.5%
- 검색 정답 supervision 없이 학습
- 복잡한 pipeline SOTA와 4.3p 이내

Index Hot-swap

- Wikipedia 2016 ↔ 2018 인덱스 교체 실험
- 국가 지도자 질문: 일치 시 68–70% 정확도
- 불일치 시 4–12% → 재학습 없이 지식 갱신

Limitations

검색 의존성과 지식원의 한계

- Wikipedia 단일 코퍼스만 사용. 검색이 틀리면 생성도 오염되며, 코퍼스의 편향·오류가 그대로 반영됨

Retrieval collapse

- 일부과제(특히 긴 생성)에서 Retriever가 입력과 무관하게 같은 문서만 반환하는 현상 발생

불완전한학습·비용

- Document encoder와 인덱스는 고정(재인덱싱 비용). 21M 패시지 인덱스 유지와 검색 지연 비용

여전한 hallucination과 오용 가능성

- 검색해도 사실과 다른 생성 가능. 허위 정보 생성 등 오용 위험 존재

Conclusion & Impact

하이브리드 메모리 패러다임 제시

- 파라메트릭(BART)과 비파라메트릭(Wikipedia 인덱스) 메모리를 end-to-end로 결합
- 지식 집약 과제에서 SOTA 달성

핵심기여

- 검색 라벨 없이 Retriever·Generator를 함께 학습, 생성형 모델에서 지식 갱신(인덱스 교체)과 출처 제시 가능성 확보

현대LLM 생태계에 미친영향

- 이후 RAG가 LLM 기반 QA·챗봇·에이전트의 표준 구조로 자리잡는 출발점이 된 연구