
Training Language Models to Follow Instructions with Human Feedback

InstructGPT · Ouyang, Wu, Jiang, Almeida, Wainwright et al. (OpenAI) · NeurIPS 2022

Paper Review

Key Terms

RLHF (Reinforcement Learning from Human Feedback)

인간의 선호 판단(preference judgment)을 reward signal로 사용해 language model을 fine-tuning하는 방법.

SFT (Supervised Fine-Tuning)

labeler(사람)가 작성한 demonstration 데이터 (정답지) 로 GPT-3를 supervised learning 방식으로 fine-tuning한 모델.

RM (Reward Model)

labeler의 output ranking 데이터로 학습되며, prompt-response 쌍에 대해 scalar reward를 예측하는 모델

PPO(Proximal Policy Optimization) / PPO-ptx

RM을 기준으로 SFT policy를 fine-tuning하는 방법. PPO-ptx는 pretraining gradient를 섞어 성능 저하를 완화.

InstructGPT (= PPO-ptx)

SFT → RM → PPO/PPO-ptx 과정을 거쳐 얻어진 최종 모델. 별도 언급이 없으면 PPO-ptx 모델을 지칭.

Motivation: The Alignment Problem

Bigger ≠ Better at Following Intent

모델 크기가 크다고 더 나은 결과가 나오는 것이 아니다.

The Objective Mismatch

- Pretraining objective: 인터넷 텍스트에서 다음 token을 예측하는 것
- 원하는 objective: 사용자의 instruction을 helpful하고 safe하게 따르는 것

연구 목표: 모델을 Helpful, Honest, Harmless 하게 만들기

모델 크기를 키우기보다, human feedback을 활용한 fine-tuning(RLHF)으로 GPT-3를 사용자 의도에 맞게 align 시켜 보자.




Figure 1. 1.3B InstructGPT가 175B GPT-3보다 선호됨.


Method: Three-Step RLHF Pipeline

SFT


Step 1

Collect demonstration data, and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.



This data is used to fine-tune GPT-3 with supervised learning.




RM


Step 2

Collect comparison data, and train a reward model.


A prompt and several model outputs are sampled.



A labeler ranks the outputs from best to worst.



This data is used to train our reward model.



PPO

Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.



The policy generates an output.



Once upon a time...

The reward model calculates a reward for the output.



The reward is used to update the policy using PPO.




Results: Labelers Strongly Prefer InstructGPT


175B InstructGPT가 더 선호된 비율:

- 175B GPT-3 대비: $85 \pm 3\%$
- Few-shot 175B GPT-3 대비: $71 \pm 4\%$
- 1.3B InstructGPT(100배 작은 모델)도 175B GPT-3보다 선호 됨

*모델 앞에 붙은 숫자 = parameter 개수



Results: Truthfulness and Toxicity



Truthfulness: hallucination 비율이 GPT-3의 41%에서 InstructGPT의 21%로 감소.

Toxicity: "respectful" prompt를 줄 때 약 25% 덜 toxic한 output 생성; prompt가 없으면 그 효과는 사라짐. (ex. 예의 바르게 대답해줘.)

Bias: Winogender (성별 고정관념 테스트) / CrowS-Pairs (사회적 편견 테스트)에서는 유의미한 개선이 없음.

Limitations

Model Behavior

- hallucination 발생, false-premise instruction을 잘못 처리하며, 단순한 질문에도 과도하게 얼버무리거나 확답을 피함
- 여러 개의 explicit constraint(예: 정확한 문장 수)를 동시에 만족시키기 어려움
- harmful하더라도 instruction을 그대로 따르는 경향이 있음; 편향되게 답하도록 유도하면 오히려 더 toxic해짐

Methodology

- 약 40명의 영어권 contractor의 선호에 맞춰 align된 것으로, 더 넓은 의미의 "human values"를 대표하지는 않음
- dataset의 96% 이상이 영어

Conclusion & Impact

Human Feedback을 활용한 Fine-tuning은 적은 비용으로 큰 효과를 내는 Alignment 수단

- 175B PPO-ptx: fine-tuning에 60 petaflops/s-days 소요, GPT-3 pretraining은 3,640 petaflops/s-days
- InstructGPT는 거의 학습되지 않은 non-English instruction과 code task에도 어느 정도 generalization을 보임
- PPO-ptx는 public NLP benchmark에서 발생한 성능 저하("alignment tax")의 대부분을 회복시킴

Significance

ChatGPT를 비롯한 이후 대부분의 instruction-tuned LLM의 기반이 된 SFT → RM → PPO 방식을 정립함.