
Chain-of-Thought Prompting Elicits Reasoning in Large Language Models

Wei, Wang, Schuurmans, Bosma, Ichter, Xia, Chi, Le, Zhou (Google Research) · NeurIPS 2022

Paper Review

Key Terms

Chain of Thought (CoT)

최종 답에 도달하기까지의 중간 추론 단계들을 자연어 문장으로 풀어쓴 것.

CoT Prompting

few-shot exemplar에 정답뿐 아니라 chain of thought까지 함께 제시해 모델이 추론 과정을 생성하도록 유도하는 방법.

Standard Prompting

input-output 쌍만 exemplar로 제공하는 기존의 few-shot prompting 방식 (baseline).

Emergent Ability

모델 크기가 일정 규모(~100B parameter) 이상으로 커졌을 때만 나타나는 능력. CoT의 효과도 여기 해당.

Solve Rate

벤치마크 문제를 올바르게 푼 비율(%)로, 이 논문의 핵심 성능 지표.

Motivation: Two Limited Ideas, Combined

Idea 1 — Rationale-Augmented Training/Finetuning

- 자연어 rationale(중간 설명)을 생성하도록 모델을 훈련시키면 reasoning에 도움이 됨
- 한계: 고품질 rationale 데이터셋을 대량으로 만드는 비용이 매우 큼

Idea 2 — Few-shot Prompting

- input-output exemplar 몇 개만 prompt에 넣어주면 별도 fine-tuning 없이 task 수행 가능
- 한계: arithmetic, commonsense, symbolic reasoning처럼 복잡한 task에는 잘 안 통하고, 모델을 키워도 크게 개선되지 않음

→ 이 논문의 제안: $\langle \text{input, chain of thought, output} \rangle$ 형태의 exemplar로 두 아이디어의 장점만 결합

Method: Standard vs. Chain-of-Thought Prompting




Figure 1: Chain-of-thought prompting enables large language models to tackle complex arithmetic, commonsense, and symbolic reasoning tasks. Chain-of-thought reasoning processes are highlighted.

Figure 1. CoT prompting은 정답 이전에 추론 과정을 함께 제시해 복잡한 문제를 풀게 함.

Experimental Setup

Tasks & Benchmarks

- Arithmetic: GSM8K, SVAMP, ASDiv, AQuA, MAWPS
- Commonsense: CSQA, StrategyQA, Date, Sports, SayCan
- Symbolic: Last Letter Concatenation, Coin Flip

Models

- GPT-3 (350M~175B)
- LaMDA (422M~137B)
- PaLM (8B~540B), UL2 20B, Codex도 일부 사용

Prompting

- Few-shot exemplar 8개(대부분 task 공통), CoT는 사람이 직접 작성
- 모든 실험에서 greedy decoding 사용
- 별도 fine-tuning 없이 prompt만으로 평가

모델 fine-tuning 없이, exemplar만 바꿔서 성능을 비교하는 순수 prompting 연구.

Results: New SOTA on GSM8K with Prompting Alone

PaLM 540B + CoT prompting = GSM8K solve rate 57%

- PaLM 540B standard prompting: 18%
- Finetuned GPT-3 175B (+verifier): 33%
- 기존 prior best(task-specific finetuned model): 55%

→ 별도 training dataset이나 fine-tuning 없이, 단 8개의 CoT exemplar만으로 기존 state-of-the-art를 능가.






Figure 2: PaLM 540B uses chain-of-thought prompting to achieve new state-of-the-art performance on the GSM8K benchmark of math word problems. Finetuned GPT-3 and prior best are from [Cobbe et al. \(2021\)](#).

Results: CoT is an Emergent Ability of Model Scale



- 작은 모델에서는 CoT prompting이 거의 효과가 없거나 오히려 성능을 해침
- ~100B parameter 이상 규모에서만 standard prompting 대비 뚜렷한 성능 향상이 나타남
- 문제가 복잡할수록(GSM8K) CoT의 이득이 크고, 쉬운 문제(SingleOp 등)일수록 이득이 작거나 없음
- 작은 모델은 fluent하지만 논리적으로 틀린 chain of thought를 생성하는 경향이 관찰됨

Results: Generalizes to Commonsense Reasoning



StrategyQA: PaLM 540B + CoT 75.6% vs. 기존 prior best 69.4%

Sports Understanding: 95.4%로 비숙련 인간 평균(84%)을 상회

CSQA: 다른 task 대비 CoT의 이득이 상대적으로 작음

Ablation, Robustness & Symbolic Reasoning

Ablation Study

- Equation only: GSM8K에는 거의 도움 안 됨 (자연어 추론 없이는 식으로 바로 변환하기 어려움)
- Variable compute only(점만 출력): baseline과 성능 비슷 → 단순히 연산 토큰 수 늘리는 게 핵심이 아님
- Reasoning after answer: baseline과 성능 비슷 → 순차적 추론 자체가 중요함을 시사

Robustness

- 다른 annotator가 작성한 CoT, 다른 exemplar 스타일, GSM8K training set에서 뽑은 exemplar로도 일관되게 standard prompting을 능가
- Linguistic style에 크게 의존하지 않음

Symbolic Reasoning

- Last Letter Concatenation, Coin Flip에서 in-domain 성능 대폭 향상
- Exemplar보다 step 수가 많은 out-of-domain(OOD) 입력에도 length generalization 가능
- 단, 이 능력도 ~100B 이상 규모에서만 나타남

Limitations

Reasoning의 본질

- CoT가 인간의 사고 과정을 모방하긴 하지만, 신경망이 실제로 "reasoning"을 하는 것인지는 여전히 열린 질문
- 정답을 맞혀도 chain of thought 자체는 틀린 논리를 담고 있는 경우가 존재(수작업 오류 분석에서 확인)

비용 및 확장성

- Few-shot에서는 CoT 작성 비용이 적지만, fine-tuning에 활용하려면 대량의 CoT 데이터 제작 비용이 커질 수 있음
- 생성된 reasoning path가 항상 옳다는 보장이 없음(정답을 우연히 맞히는 경우 포함)
- CoT reasoning이 대규모 모델에서만 발현되므로, 작은 모델을 실서비스에 쓰는 경우 비용 부담이 큼

Conclusion & Impact

Prompting만으로 Reasoning 능력을 이끌어낼 수 있음을 실증

- 별도의 training dataset이나 fine-tuning 없이, few-shot exemplar에 chain of thought만 추가해 arithmetic, commonsense, symbolic reasoning 전반에서 큰 성능 향상
- Standard prompting은 flat한 scaling curve를 보이지만, CoT prompting은 모델 규모에 따라 급격히 증가하는 scaling curve를 만들어 냈
- 즉, standard prompting은 large language model의 능력에 대한 하한선(lower bound)일 뿐임을 시사

Significance

이후 self-consistency, zero-shot CoT("Let's think step by step"), tree-of-thought 등 수많은 후속 prompting 기법의 출발점이 된 논문.