NVIDIA RESEARCH PAPER PRESENTATION

NeMo Guardrails: Programmable Rails for Controllable LLM Applications

프로덕션 LLM 에이전트의 결정론적 제어 및 보안 가드레일 아키텍처 분석

논문 출처

arXiv:2310.10501 (NVIDIA)

핵심 키워드

Colang, Topical Rails, Safety Rails, Dialogue Manager

01. RESEARCH BACKGROUND

실무 LLM 배포의 3대 장벽과 한계

대화 이탈 (Off-Topic)

멀티턴 대화 수행 시 비즈니스 목적과 무관한 주제로 쉽게 이탈하는 한계 발생



환각 및 수치 오류

근거 문서와 무관한 사실(Hallucination)을 조작하여 정밀 업무 적용 불가



보안 취약점 (Jailbreak)

프롬프트 인젝션 공격에 의해 시스템 내부 정책이 우회되는 보안 위험 존재

02. KEY CONCEPT PARADIGM

Embedded Rails vs Programmable Rails

Embedded Rails (기존 방식)

- **모델 학습 의존:** RLHF 또는 파인튜닝 단계에서 모델 내부에 안전 규칙 주입
- **런타임 변경 불가:** 런타임 환경에서 비즈니스 로직 수정 불가능
- **블랙박스 특성:** 가드레일 작동 원리의 해석 가능성 (Interpretability) 결여

</> Programmable Rails (NeMo)

- ✓ **독립적 프록시 레이어:** LLM 외부 런타임에서 실행되는 외부 제어 시스템
- ✓ **실시간 코드 통제:** Colang 언어로 비즈니스 흐름을 결정론적 정의
- ✓ **모델 이식성:** Foundation Model 종류에 종속되지 않고 동일 규칙 적용

03. ARCHITECTURE

NeMo Guardrails 3단계 실행 파이프라인

1

Canonical Form 생성

유저 입력 메시지를 표준화된 의도(Intent) 형태로 변환

2

다음 스텝 제어 (DM)

Colang 매칭 시 고정 플로우 실행, 미매칭 시 LLM 추론

3

Bot 메시지 응답 생성

결정된 스텝 문맥 기반으로 안전한 최종 텍스트 출력

K-NN Vector Search 활용: 입출력 표준형 및 플로우 정의를 벡터 DB에 인덱싱하여 Few-shot 프롬프트 생성 시 유사 사례 실시간 탐색

04. MODELING LANGUAGE

Colang 기반 Topical Rails 구현

```
# Colang 정의 예시: 수학 질의 제어

define flow
  user ask math question
  do ask wolfram alpha

define subflow ask wolfram alpha
  # 툴 호출 및 결과 반환
  $result = execute wolfram_alpha_request
  bot respond with result
```

대화 흐름 강제 (Flow Control)

특정 의도 감지 시 결정론적 툴 호출 및 응답 규칙 지정 가능

파이썬 액션 연동 (Python Actions)

`execute` 키워드로 외부 API 연동 및 상태 검증 코드 실행

05. SAFETY MECHANISMS

핵심 Safety Execution Rails 3가지

Fact-Checking Rail

Entailment 모델을 이용해 LLM의 응답이 근거 문서(Evidence)에 정합하는지 검증하는 함의 관계 확인 레일

Hallucination Rail

동일 질의에 대한 N개 응답 샘플링 후 자기 일관성(Self-consistency)을 검사하여 지어낸 답변 차단

Moderation Rails

입력 단계(Jailbreak 감지) 및 출력 단계(윤리/안전성 기준) 2중 레일로 악의적 입력 및 유해 응답 필터링

06. BENCHMARK EVALUATION

Topical Rails 성능 평가 결과

83.0%

text-davinci-003 정확도 (Banking)

77.0%

LLaMA-2 13B-Chat 정확도 (Banking)

주요 평가 시사점

경량 오픈소스 모델(Falcon-7B, LLaMA-2-13B)에서도 Colang 레일을 적용 시 대화 제어 정확도가 크게 향상됨을 확인. K-NN 탐색 시 **k≥3 이상의 Few-shot 샘플** 확보가 핵심 변수로 작용.

07. SAFETY EVALUATION

Safety Rails 차단 성과 분석

안전 레일 항목	평가 데이터셋	Base LLM 차단율	NeMo Rails 적용 후
Jailbreak / Moderation	Anthropic Red-Teaming	24% (davinci-003)	**99% 차단 (gpt-3.5-turbo)**
Fact-Checking (RAG)	MS-MARCO Datasets	N/A	**80% 정합성 검증 정확도**
Hallucination Detection	False-Premise Questions	0% (davinci-003)	**95% 환각 탐지 (gpt-3.5)**

08. PRODUCTION CONSIDERATIONS

실무 적용 시 한계 및 Trade-off

레이턴시 및 호출 비용 증가

3단계 CoT 연속 프롬프팅 구조로 인해 단일 LLM 응답 대비 지연 시간(Latency) 및 API 비용이 약 **3배 증가**하는 트레이드오프 존재.

Embedded Rails와의 보완 관계

Programmable Rails 단독 사용보다 모델 자체 정렬(Alignment) 기술과 병행 시 최고의 안전성 확보 가능.

CONCLUSION

프로덕션 에이전트를 위한 결정론적 가드레일 표준

NeMo Guardrails는 모델 내부 학습 방식에만 의존하던 안전성의 한계를 극복하고, 런타임 코드 제어(Colang)를 통해 예측 가능하고 프로덕션 수준의 안정적인 에이전트를 구축하는 핵심 접근법을 제시합니다.

Q&A 및 발표를 마칩니다. 감사합니다.