

Set-of-Mark Prompting

Unleashes Extraordinary Visual Grounding in GPT-4V

Yang, Zhang, Li, Zou, Li, Gao

Microsoft Research · HKUST · UW-Madison

arXiv:2310.11441 (2023.11)

보기는 하는데, 가리키지 못한다

GPT-4V 등장 당시의 이상한 구멍

장면 이해

상황 설명, 농담 이해, 그래프 읽기
— 놀라울 만큼 잘 함

위치 지칭

개 한 마리, 신호등 몇 개의 좌표조차
제대로 못 짚음

= fine-grained visual grounding 의 부재

그림 전체를 훌륭하게 감상평하는 사람이, "왼쪽에서 세 번째 접시"는 못 짚는 상태

왜 좌표를 못 뽑는가

기존 방식

"개는 (0.34, 0.51, 0.62, 0.88)에 있습니다"

이 방식이 두 가지를 동시에 망가뜨린다

LLM 쪽

자연어 흐름 중간에 정밀 숫자를 끼워
넣으면 언어 능력 자체가 흔들린다

비전 쪽

비전 인코더가 이미 가진 공간 정보가
텍스트 토큰을 거치며 소실된다

문제는 능력이 아니라 출력 형식이다

텍스트가 아니라 이미지를 고친다

지금까지의 프롬프트 엔지니어링

출력 = F (이미지 , 텍스트)

이 논문

출력 = F (SoM(이미지) , 텍스트)

CoT, few-shot, 역할 부여 — 전부 텍스트 쪽 이야기였다.

텍스트는 그대로 두고, 입력 이미지만 바꾼다.

빨간 동그라미로는 안 되는 이유

기존 visual prompting — 빨간 원, 영역 하이라이트, 화살표 달린 원

한 두 개만 가리킬 수 있다

동그라미 하나로는 "이거" 뿐.
물건이 20개면 쓸 수 없다.

말할 수 없다 (not speakable)

빨간 동그라미를 문장 안에서
뭐라고 부를 것인가.

마커는 눈으로 보이면서 동시에 입으로 말할 수 있어야 한다

숫자와 알파벳이 정확히 그렇다 — 이미지에 그릴 수도 있고, 문장 안에 쓸 수도 있다

Set-of-Mark, 3단계



결과

"오른쪽 노트북은 9번, 램프는 12번입니다"

학습 없음 · 파인튜닝 없음 · 이미지에 숫자를 그렸을 뿐

① 영역 분할

기성 세그멘테이션 모델로 이미지를 K개 영역으로 쪼갬다

높은 정밀도

영역이 정확해야 공간 정보가 전달된다

MaskDINO

오픈 보캐블러리

미리 정해둔 목록 밖의 물체도 인식

SEEM

다양한 granularity

물체 전체뿐 아니라 부분도 잡아야 한다

SAM, Semantic-SAM

"의자"만이 아니라 "의자 등받이"도 잡을 수 있어야 한다

② 어떤 마커를 쓸까

영숫자 중심

자리를 적게 차지해 원본을 덜 가리고,
GPT-4V가 OCR로 읽을 수 있다

보조 마커

박스, 마스크 경계선을 함께 그린다

주의 — 마커 타입은 이미지에 따라 달라져야 한다

- 숫자 가득한 수식 이미지에 숫자 마커를 찍으면 원본과 헷갈린다
- 문서 스크린샷에 알파벳 마커를 찍어도 마찬가지

자동 선택은 향후 과제로 남겼다

② 어디에 찍을까

"중심에 찍으면 되지 않나?" — 안 된다

밀집하면 겹친다

중심점들이 서로 충돌한다

오목한 영역은 바깥에 찍힌다

도넛의 중심은 도넛이 아니다

마커 할당 알고리즘

1 면적 오름차순 정렬

작은 영역부터 자리를 준다

2 앞선 영역이 덮은 부분 제외

이미 찬 공간은 후보에서 뺀다

3 **distance transform**

경계에서 가장 먼 지점을 찾는다

지도에 국가명을 겹치지 않게 써넣는 문제와 같다

마커에 대해 아무것도 알려주지 않았다

텍스트 입력에 마커 정보는 일절 누출되지 않았다

그럼에도 GPT-4V는

숫자 마커가 무슨 의미인지 이해하고,
언제 어떻게 시각 내용과 연결할지 스스로 판단했다

저자들의 규정 — emergent ability

단, 2023년 시점의 관찰이다. 다른 LMM들은 마커를 "말해내지" 못했다.

결과

RefCOCOg REC · ACC@0.5 · 제로샷

25.7

좌표를 직접 생성



86.4

SoM 적용

제로샷으로 앞선 상대

전문가 모델 — PolyFormer, Grounding DINO (해당 태스크로 완전 파인튜닝)

오픈소스 LMM — LLaVA-1.5, Shikra, MiniGPT-v2, Ferret

그 외 — Flickr30K 구문 grounding 89.2 R@1 · DAVIS2017 영상 객체 분할 78.8 J&F

무엇이 성능을 결정하는가

마커 구성

숫자 + 마스크	84.4
----------	------

+ 박스	89.2
------	------

Flickr30K R@1 · 박스 하나 더 그렸을 뿐

마스크 품질

MaskDINO 예측	75.6
-------------	------

정답 마스크	90.1
--------	------

RefCOCOg mIoU · 14.5 포인트 갭

SoM은 문을 열어주지만,
방의 크기는 세그멘테이션이 정한다

정답 마스크를 써도 남은 실패 사례는 대부분 어노테이션 자체가 모호하거나 틀린 경우였다

한계와 열린 질문

논문이 인정한 것

- 마커 타입 자동 선택이 미해결 — 이미지마다 수동으로 골라야 한다
- 세그멘테이션 의존성 — 14.5 포인트 갭
- GPT-4V에서만 작동 — 다른 LMM은 마커를 말해내지 못했다

지금 던질 수 있는 질문

- 2026년 모델에서도 여전히 GPT-4V 전용 현상인가
- 실험은 전부 일반 사진이었다 — 선화 다이어그램, 설계도에서도 통하는가