

Magma: A Foundation Model for Multimodal AI Agents

Yang et al., CVPR 2025

Microsoft Research · University of Maryland · UW-Madison · KAIST · University of Washington

microsoft.github.io/Magma

01

문제 정의: 에이전트 모델의 분리

디지털 — UI 내비게이션

Pix2ACT, Ferret-UI

물리 — 로봇 조작

RT-2, OpenVLA

범용(generalist)을 표방하지만, 대부분 특정 행동 정책 학습에 집중한 대가로 일반적인 멀티모달 이해 능력이 크게 떨어져 있음.

02

같은 수식을 사용하나 출력 간의 차이점이 있음.

$$O = \pi(I, \text{task}) \quad I \in \{\text{verbal}, \text{spatial}\}$$

UI 내비게이션

행동 종류(click, type) + 위치 (x, y) 또는 박스 (x, y, w, h)

로봇 조작

6자유도 변위 (x, y, z, yaw, pitch, roll) + 그리퍼 개폐

VQA

텍스트 설명, 경우에 따라 위치

로봇 행동은 2D 이미지에 근거하지 않는다 → 공동 학습을 가능하게 할 통합 인터페이스가 필요

03

클릭할 버튼도 3번, 집어야 할 물체도 3번 -> 마킹을 통해 해결

모델은 원래의 2D·3D 출력을 예측하는 것보다 숫자 마커를 고르는 것을 훨씬 덜 어려워한다

$$o = \{\text{action} : \text{mark}\} = \pi(\text{IM}, \text{task})$$

원논문 (SoM)과 마킹 방식의 차이점

	SoM (2023)	Magma, Algorithm 1
후보 영역	세그멘테이션 모델 SAM, SEEM, Semantic-SAM	웹은 DOM 트리 모바일은 뷰 계층
마커 위치	distance transform 경계에서 가장 먼 내부 점	FindOptimalCorner 이전 박스들에서 가장 먼 모서리
용도	기성 LMM을 프롬프팅	시각 프롬프트 인식을 학습

제로샷 평가에는 OmniParser, 다운스트림에는 데이터셋이 제공하는 원래 박스를 사용

05

SoM을 시간 축으로 늘린 것이 Trace-of-Mark

현재 프레임의 마커가 다음 l개 프레임에서 어디로 이동하는지, 그 궤적을 예측하게 함

시간을 앞서 보게 만든다

궤적을 맞추려면 앞으로 무슨 일이 일어날지 알아야 하므로, 행동 전에 시간적 역학을 이해하도록 강제된다

프레임 예측보다 싸다

토큰을 훨씬 적게 쓰면서 더 긴 시간 지평을 담고, 행동과 무관한 배경은 무시한다

06

Algorithm 2 — 라벨 없는 영상에서 궤적 추출

1	CoTracker로 점 추적	15×15 격자 점을 뿌려 픽셀 단위 궤적을 얻는다
2	호모그래피 변환	카메라 전역 움직임을 제거한다. 1인칭·3인칭 영상 모두에서 효과적
3	전경·배경 분리	평균 움직임 크기가 ε 이상인 궤적만 전경으로 분류
4	K-means 클러스터링	전경과 배경을 따로 묶어 대표 궤적만 남긴다

$s = 15, \eta = 2, \varepsilon = 2$

07

모든 주석을 언어 토큰으로 바꿔서 학습

2D 행동

텍스트 딕셔너리로 변환

로봇 행동

LLM 어휘의 마지막 256개 이산 토큰에 할당

좌표

이미지 크기로 정규화한 뒤 256구간으로 양자화

백본

LLaMA-3-8B + ConvNeXt-XXlarge (임의 해상도 지원)

"팔을 3cm 움직여"가 특정 토큰 하나가 되므로, 평범한 LMM 학습 방식을 그대로 쓸 수 있음

08

3,900만 샘플, 전부 SoM과 ToM으로 자동 라벨링

멀티모달 이해	ShareGPT4V, LLaVA-1.5 instruction tuning, OCR 계열 (Magma-SFT 820K)
로봇 조작	Open X-Embodiment
UI 내비게이션	SeeClick, Vision2UI
교육용 영상	Epic-Kitchens, Ego4D, Something-v2 등 목표 지향 인간 행동 영상

원래 행동 라벨이 없던 이미지와 영상을 "비전-언어-행동" 데이터로 변환한 것이 실질적 기여

Table 3 — 데이터 합치기

모델	SoM+ToM	VWB-Act-G	SE-Bridge	SE-Google
Magma-8B (UI) — UI만	없음	58.3	—	—
Magma-8B (OXE) — 로봇만	없음	—	22.2	35.7
Magma-8B (ACT) — UI + 로봇	없음	21.4	17.5	31.5
Magma-8B (Full) — 영상까지	없음	25.2	17.7	37.5
Magma-8B (Full)	적용	71.8	35.4	52.3

기여: 서로 다른 데이터를 같은 형식으로 바꾸는 방법을 찾음

파인튜닝 X, 행동 능력을 얻고도 이해 능력을 유지함

지표	Magma-8B	비교 대상
VWB-Ele-G (웹 요소 찾기)	96.3	GPT-4V 67.5
SE-Google Robot	52.3	OpenVLA 31.7
SE-Bridge	35.4	OpenVLA 14.5
VQAv2 / TextVQA / POPE	80.0 / 66.5 / 87.4	LLaVA-1.5 78.5 / 58.2 / 85.9

로봇 조작에서 2위 OpenVLA를 20.8% 차이로 앞서 평균 성공률이 거의 두 배 · 실제 WidowX 로봇 4개 과제에서도 67.5% vs 25.0%

11

숫자를 볼 때 감안할 것

사후 학습 단계가 없다

지시를 잘 따르지 못해 답변 선택지를 온전히 출력하는 것조차 어려워한다. 표준 옵션 매칭을 쓰면 성능이 크게 오른다고 각주에 밝히고 있다

모든 지표에서 이기지 않는다

Table 5의 SpatialEval Spatial Map은 SoM/ToM 없는 쪽이 41.5, 있는 쪽이 33.9. Maze Nav.와 Spatial Grid는 반대

SoM의 한계 -> 그 능력을 학습시켜 버리는 방식으로 우회한 후속 연구

	SoM (2023)	Magma (2025)
정체	프롬프팅 기법	파운데이션 모델
마커의 역할	추론 시 입력을 바꾸는 장치	학습 신호
대상 모델	GPT-4V에서만 작동	직접 학습
시간 축	없음	ToM으로 확장