OmniParser for Pure Vision Based GUI Agent

Lu, Yang, Shen, Awadallah
Microsoft Research · Microsoft Gen AI · arXiv:2408.00203

github.com/microsoft/OmniParser

01

SoM의 번호 라벨링 -> HTML 기반 문제

현재의 SoM 기반 해법들은 버튼 같은 행동 가능 요소의 박스를 뽑기 위해 파싱된 HTML 정보에 의존하며, 이것이 용도를 웹 브라우징 과제로 제한하고 있음.

되는 것

웹 브라우저 — DOM 트리
안드로이드 — 뷰 계층

안 되는 것

윈도우·맥OS 데스크톱 앱
PhotoShop, Office365, 게임, 임의의 화면

논문의 주장 — 기존의 순수 비전 기반 화면 파싱이 만족스럽지 못해, GPT-4V의 이해 능력이 심각하게 과소평가되고 있음.

02

화면 이해와 행동 예측 분리

의미 추출을 파싱 단계에서 미리 떼어내면 GPT-4V의 부담이 줄어 행동 예측에 집중할 수 있다

아이콘 탐지
YOLOv8
상호작용 가능 영역

+

OCR
텍스트 박스
겹침 90% 초과 시 제거

+

아이콘 설명
BLIP-2
기능 의미 추출

번호와 박스가 씌워진 스크린샷 / 텍스트와 아이콘 설명을 담은 local semantics

DOM 비슷한 구조화된 표현을 비전만으로 복원

03

데이터셋

탐지 — 6만 7천 장

ClueWeb22 인기 URL 10만 개를 샘플링해, 각 페이지의 DOM 트리에서 상호작용 가능 영역의 박스를 수집

YOLOv8, 20에폭, 배치 256, GPU 4장

설명 — 7,185쌍

탐지된 아이콘 박스를 GPT-4o에 넣어 기능을 한 문장으로 설명하게 함. 아이콘이 아니면 그 사실도 데이터에 포함

BLIP-2, 1에폭 파인튜닝

아이콘	원본 BLIP-2	파인튜닝 후
톱니바퀴	회색과 흰색의 톱니바퀴 이미지	**Settings**
Discord	웃는 얼굴이 있는 주황·흰색 로고	**메시징·음성 채팅 애플리케이션**

04

SeeAssign — 박스가 많아지면 번호를 잘못 고르는 문제

직접 만든 112개 과제 · 박스 개수로 난이도 구분 (쉬움 10개 미만 / 보통 10~40개 / 어려움 40개 초과)

조건	쉬움	보통	어려움	전체
GPT-4V, 설명 없음	0.913	0.692	0.620	0.705
GPT-4V, 설명 있음	**1.00**	**0.949**	**0.900**	**0.938**

설명이 없으면 과제가 요구하는 아이콘과 실제 번호를 연결하지 못해 환각으로 이어짐.

05

ScreenSpot — 같은 GPT-4V 모델 사용, 화면을 보여주는 방식 변경으로 해결

방법	크기	평균
GPT-4V	—	**16.2%**
CogAgent (GUI 데이터로 파인튜닝)	18B	47.4%
SeeClick (GUI 데이터로 파인튜닝)	9.6B	53.4%
OmniParser — 설명 없음, Grounding DINO	—	58.4%
OmniParser — 설명 추가	—	68.7%
OmniParser — 설명 + 자체 탐지 모델	—	**73.0%**

설명 추가 +10.3 · Grounding DINO를 자체 탐지 모델로 교체 +4.3

데스크톱 Icon/Widget 항목은 GPT-4V 11.8% → 63.6%

06

결과

Mind2Web · Step Success Rate

방법	HTML 없음	Cross-Website	Cross-Domain	Cross-Task
GPT-4 (HTML 사용)	아니오	30.1	26.4	36.2
GPT-4V + SoM (HTML 박스)	아니오	32.7	23.7	20.3
GPT-4V + textual choice	아니오	32.4	36.8	40.2
OmniParser	**예**	**36.5**	**42.0**	39.4

모바일 AITW에서도 GPT-4V + history 53.0 → 57.7 · 웹페이지로 학습한 탐지 모델이 모바일 화면에 일반화됨.

07

실패하는 세 가지 경우

반복되는 요소

알람 화면에 똑같은 토글이 7개. 7:30을 켜야 하는데 정답은 27번. 생긴 게 같으면 번호를 붙여도 구별할 근거가 없다

박스 입도

'MORE'를 감싸는 더 큰 박스를 잡았는데, 클릭 지점을 박스 중심으로 계산해 실제 영역 바깥에 떨어진다. OCR에는 클릭 가능 여부라는 개념이 없다

아이콘 오해석

점 세 개를 "로딩 또는 버퍼링 표시기"로 설명. 설명 모델이 잘라낸 아이콘만 볼 뿐 전체 그림을 보지 못하기 때문

해법: 반복 요소에 세밀한 설명, OCR과 탐지를 하나로 합친 모델, 전체 맥락을 보는 설명 모델

08

지난 논문 리뷰 비교

	SoM (2023)	OmniParser (2024)	Magma (2025)
질문	번호를 붙이면 되나?	**번호를 어떻게 붙이나?**	번호로 학습시키면 되나?
영역 출처	세그멘테이션 모델	**스크린샷만**	DOM / 뷰 계층
마커 배치	distance transform	겹침 최소화 알고리즘	FindOptimalCorner
대상	GPT-4V 프롬프팅	GPT-4V 프롬프팅	직접 학습